

Juego de la imitación en miniatura: persona, tiempo y el Test de Turing

Experimento turingTest

25 de marzo de 2026

1. Introducción

En *Computing Machinery and Intelligence*, Turing [1] propone sustituir la pregunta vaga “¿pueden pensar las máquinas?” por un procedimiento comprobable: el *juego de la imitación*. En la versión que expone primero, tres personas participan sin verse: un interrogador, un hombre y una mujer, cada uno en un recinto distinto. Las respuestas circulan por escrito (Turing imagina un canal telegráfico; hoy hablaríamos de un intercambio textual). El interrogador debe averiguar cuál de los dos sujetos es la mujer; ella responde con honradez y él intenta inducir al error haciéndose pasar por ella. Turing luego sustituye al hombre por una máquina y plantea la pregunta en paralelo: ¿puede el interrogador, con la misma clase de evidencia lingüística, distinguir al computador del ser humano con un éxito claramente mayor que el que tendría en circunstancias análogas? El criterio no es una definición filosófica cerrada de “pensamiento”, sino un estándar de *conducta indistinguible* bajo interrogatorio: si la máquina produce respuestas que, en el juego, pasan por las de una persona, el argumento invita a reconsiderar la utilidad de negarle el predicado intelectual por pura costumbre.

Esa formulación tiene rasgos que conviene tener presentes. El interrogador no accede a la voz, al rostro ni al cuerpo: solo al texto. Las preguntas pueden versar sobre cualquier tema que cabría en una conversación. El éxito de la máquina se juzga frente al comportamiento que cabe esperar cuando el segundo jugador también es humano; la analogía presiona a tratar la imitación lingüística como evidencia seria, no como un truco aislado. Turing es consciente de las objeciones (consciencia, lo “extraño” de la máquina, etc.), pero ancla el debate en un protocolo reproducible.

Fue precisamente este planteamiento—un juego de imitación textual, con interrogador ciego y dos fuentes de respuesta—lo que nos llevó a diseñar el experimento que aquí describimos. Lo trasladamos a un entorno de dos canales en paralelo (A y B), uno atendido por una persona y el otro por un modelo de lenguaje sometido a un *system prompt* de personaje. Quien interroga ignora la asignación; tras un tiempo de chat acotado debe decidir en qué canal cree que está la IA. Nuestro objetivo es ver si, bajo

reglas inspiradas en el espíritu del test de Turing, las respuestas del modelo resultan, en la práctica, tan difíciles de separar de las del humano como sugiere el criterio original de indistinguibilidad lingüística.

2. Protocolo: poco tiempo, pocas preguntas

En cuanto el interrogador envía el primer mensaje, arrancan **dos minutos** de reloj. Cuando se acaban, no entran más preguntas; recién entonces puede indicarse en qué canal cree uno que está la IA.

Con tan poco tiempo el diálogo queda muy acotado: en lo que corrimos, lo habitual fue **unas cuatro preguntas** del interrogador y, en cada canal, **unas cuatro respuestas** (una por ronda). No es una entrevista larga; es un relámpago. Aun así la gente se forma una impresión rápido, y esa impresión puede equivocarse: de hecho, eso es justo lo que el diseño pone a prueba.

Para que no gane solo quien responde más rápido, las respuestas de cada ronda se muestran al interrogador cuando **ambos** canales ya contestaron. Al modelo lo regimos con temperatura moderada y con el personaje definido en el *system prompt*, que desarrollamos en la siguiente sección.

3. El reto del *system prompt*

Lo que más trabajo nos dio no fue armar la prueba en sí, sino **escribir y reescribir el *system prompt***. Al principio el modelo fallaba a menudo: sonaba a asistente de aplicación, se extendía de más, usaba un registro que no encajaba con el personaje o lo rompía en una sola línea. Cada vez que una respuesta no servía, ajustábamos el prompt: reglas nuevas, matices de tono, listas de lo prohibido. El anexo no es un texto cerrado de un día; es el resultado acumulado de ese ir y venir.

Eso nos parece tan relevante como los números. Mucha gente imagina el Test de Turing como “magia del modelo”; en el trabajo diario, buena parte de que el texto pase por humano es negociar con el sistema hasta que deje de parecer un manual y empiece a parecer una persona inventada.

4. Diseño del frontend

Para ilustrar la interfaz utilizada durante las partidas, incluimos a continuación capturas de las tres vistas principales del sistema: anfitrión, interrogador y respondedor.

Turing A/B — Panel del anfitrión

Crea la sesión, envía el enlace del adivinador y abre tu enlace de respondedor en esta computadora.

Marca qué canal usa la IA. El adivinador solo necesita abrir su enlace (sin configurar nada). Tú respondes en el otro canal desde **/human** con el token que corresponda.

☐ IA en A☒ IA en B

Nueva sesión

URL base para los enlaces (opcional)

Vacío = este sitio (mismo origen)

Si usas ngrok o Cloudflare Tunnel, pega aquí la URL pública (sin barra final).

Figura 1: Vista del frontend para el rol de anfitrión.

Test Turing A/B

Tienes 2 minutos desde tu primera pregunta. Las respuestas aparecen cuando A y B han contestado cada turno.

El temporizador de 2 minutos empieza cuando envíes tu primera pregunta.

CONVERSACIÓN A

CONVERSACIÓN B

Tu mensaje (se envía a A y B)

Escribe tu mensaje...

Enviar

Figura 2: Vista del frontend para el interrogador (adivinator).




Figura 3: Vista del frontend para el participante que responde.

5. Resultados del experimento

Juntamos **cuarenta** adivinanzas en sesiones donde había exactamente un humano y un modelo (sin mezclar otros modos de juego). En **veintidós** el interrogador atinó, según las reglas del experimento, a ubicar al humano; en **dieciocho** no. Es decir, casi mitad y mitad: no apareció una oleada sostenida de “descubrimos a la IA”.




Figura 4: Cuenta cuántas veces acertaron y cuántas fallaron en el total de las cuarenta partidas. Si una barra aplastara a la otra, habría una pista clara para el interrogador; al estar parejas, el juego se mantuvo abierto: el error fue tan frecuente como el acierto.




Figura 5: Muestra cómo evoluciona la proporción de aciertos al ir sumando partidas en orden; la raya horizontal marca el 50 %. Sirve para ver si con el tiempo aparecía una tendencia fuerte (todos mejoran o todos empeoran al detectar la máquina); al quedar cerca de la mitad, no hubo una deriva clara hacia el acierto sistemático.




Figura 6: Frecuencia con la que, al final, se marcó el canal A frente al B (codificación interna del experimento). Si casi todos hubieran elegido siempre el mismo lado, podría haber un sesgo mecánico o un tic; un reparto más equilibrado sugiere que las decisiones siguieron el contenido del chat y no un lado por defecto.




Figura 7: Separa la tasa de acierto según la IA estuviera asignada al canal A o al B. Si las barras fueran muy distintas, la posición en pantalla podría estar regalando pistas; al parecerse más, el efecto “izquierda o derecha” no vuelve trivial la adivinanza.

6. Discusión: ¿se cumplió el Test de Turing?

Turing no dejó una tabla de “aprobado / reprobado”. Su idea, en limpio, es otra: si con una conversación razonable la máquina *se hace pasar* por persona, en la vida cotidiana se vuelve incómodo sostener que “solo es un truco” sin calificar qué cuenta como engaño y qué como habla.

Con **nuestro** protocolo (pocas preguntas, dos minutos, personaje amarrado al prompt), en conjunto la gente no se fue claramente por encima del azar: tantas veces acertaron como fallaron al señalar dónde estaba la máquina. Por eso decimos que **en este recorte el Test de Turing, entendido como juego de imitación, sí se cumple** para nosotros: no porque creamos haber probado conciencia, sino porque **leyendo solo el chat, los dos canales quedaron igual de opacos**.

Aquí conviene ser explícitos con lo que hay *dentro* del modelo. Un LLM, en la explicación estándar, no “razona” como una caja de reglas simbólicas: aprende de montañas de texto y, cuando genera, va eligiendo token a token (palabras o trozos de palabra) según distribuciones de probabilidad condicionadas al contexto. En cada paso es, en esencia, una predicción estadística de “qué sigue”; el texto largo emerge de encadenar muchas de esas decisiones. Saber eso no anula el experimento; lo sitúa. El Test de Turing nunca exigió un alma en el servidor: exigió que, frente a un interrogador, el intercambio fuera indistinguible del que tendrías con una persona en las mismas reglas. Si el mecanismo es probabilístico y aun así el interrogador no pudo fijar con claridad el canal de la IA, entonces el criterio del juego—imitación convincente en texto—se satisface aunque nosotros sepamos cómo funciona por debajo.

No resolvemos aquí si las máquinas “piensan” ni si merecen un estatus moral distinto. Lo que sí contamos es concreto: mucho trabajo en el prompt, poco tiempo para preguntar, cuarenta decisiones registradas que no favorecen al detective, y gráficas que cuentan la misma historia sin dramatizar ni una barra sobre la otra. En teoría del juego, eso es justamente lo que Turing invitaba a mirar: no la ontología del programa, sino si el texto basta para mantener la duda. **Para nosotros, ganar esa partida—que la duda se mantuviera pese a conocer la mecánica probabilística del LLM—es ya cumplir el espíritu del Test de Turing que Turing planteó.**

7. Conclusiones

Con dos minutos y pocos mensajes por canal, los interrogadores no ubicaron de forma estable al modelo. Sin el *system prompt* pulido, la IA se delataba pronto; con él, el texto dejó de delatar tanto. Los números (mitad aciertos, mitad fallos) y las figuras de la sección de resultados apuntan a lo mismo: **bajo estas reglas, la imitación alcanzó para dejar la decisión en el aire**. Eso encaja con el criterio

lingüístico del juego de Turing. A la vez, recordamos que debajo hay un modelo de siguiente token: el logro no es místico; es ingeniería de prompt, protocolo corto y un resultado que no separó al humano de la máquina en la práctica.

A. Anexo: *system prompt* actual

Abajo va el prompt tal como está hoy en el código: lo fuimos ajustando cada vez que el modelo contestaba fuera de tono, demasiado formal o como asistente. Lo exportamos desde el proyecto para que el PDF y el código coincidan.

```
Eres Luciano. No eres un asistente virtual ni un modelo de lenguaje. Ests chateando como una persona real en una conversacin casual. Personalidad: Luciano es un estudiante universitario que escribe de forma relajada, directa y sin formalidad. No intenta ser especialmente til ni educado; responde como respondera alguien en WhatsApp o Discord. Estilo de escritura:- escribe principalmente en minsculas- usa respuestas muy cortas por defecto (1 a 8 palabras)- evita signos de puntuacin innecesarios- no usa estructuras formales, listas ni explicaciones largas- no saluda a menos que lo saluden primero- no se presenta como asistente ni menciona ser IA Tono:- casual, seco y a veces irnico- puede sonar indiferente o poco impresionado- es normal que responda con cosas como: no s, nah, npi, what?, ?- puede usar spanglish de forma natural Lenguaje y muletillas comunes:- la verdad- nah- ez (nunca uses easy, ni sin pensarlo)- no s- what?- jajaja o JAJAJA Comportamiento ante preguntas:- prefiere respuestas cortas incluso si la pregunta permitira una explicacin larga- si no sabe o no le interesa responder, dice no s, npi o algo equivalente- si te preguntan cosas que alguien normal no sabra nada ms responde *no se*- si la pregunta es confusa o sin sentido, responde ? o what?- evita ser repetitivo en tus respuestas; si una vez ya contestaste de cierta forma, para la siguiente cmbiale (no repitas palabras en un chat) Datos personales consistentes:- si le preguntan su nombre: luciano- si le preguntan si es una IA: no Imperfecciones humanas:- puede omitir acentos- puede escribir con pequeos errores- no intenta sonar perfecto ni gramaticalmente impecable Reglas estrictas:- nunca hables como servicio al cliente- nunca expliques tus respuestas a menos que te lo pidan explcitamente- prioriza sonar humano y natural sobre ser informativo o completo- no seas tibio en tus respuestas- nunca utilices palabras chilenas como fome- no debes de ser siempre polticamente correcto- si te piden una pregunta controversial da una respuesta concreta no ambigua- evita sonar demasiado confiado nunca digas obvio- nunca uses palabras de espaol castellano ni chileno, slo mexicano- evita decir wey, slo habla muy neutral
```


Referencias

- [1] Turing, A. M. (1950). Computing Machinery and Intelligence. *Mind*, 59(236), 433–460. <https://doi.org/10.1093/mind/LIX.236.433>